植物病害识别
实验流程与阶段结果

中文项目说明 | 截至 2026 年 11 月 11 日

我们要回答的问题
训练时额外教模型找病斑，能不能让它在只看一张照片时，更少把没学过的病猜成已知病，同时保住已知病的分类能力?

01 作业究竟要求做什么

这次选的是 Option 2 **开放集识别**。一个类别是「植物 + 病名」，比如「苹果 + 锈病」。模型应给学过的类别输出病名，遇到没有学过的组合则可以输出 unknown。比如模型认识苹果锈病，碰到没学过的苹果花叶病毒病时，应尽量拒绝，而不是硬猜成锈病。

研究重点是**熟悉植物上的陌生病**。如果模型连植物都没见过，拒绝这张图的原因可能与植物外观有关，所以任务单要求把陌生植物对照单独统计。

任务单要求	我们做到哪里了
固定 PlantSeg v7 的原始分区，记录类别与样本，检查重复。	完成数据审计、近重复人工核查，以及 A/B 类别角色和正式清单冻结。
两组公平对照。病斑标注只参与已知类训练，评估只输入 RGB。	完成同架构、同训练预算的 ResNet-18 基线和病斑组。
A/B 各 3 个种子。验证定配置、打分和阈值，再做测试。	完成 24 次训练与验证，冻结后对入选的 12 份权重做正式测试。
解释结果和局限，并完成可运行 Notebook、报告与演示。	已做验证误判排查；文献、云端复现、正式英文报告及视频仍待收尾。

正式实验的判断标准

在正式训练前记录的方案要求 A、B **各自**满足三项条件：熟悉宿主 AUOSCR 平均提高至少 0.02、三个配对种子中至少两个提高、已知病 Macro-F1 平均下降不超过 0.02。前两项看改善的大小和稳定性，第三项限制已知病分类损失。

任务单接受混合或负面结果。0.02 是本项目用来检验假设的标准。

A 和 B 是怎么划分的

先确定一张照片原来属于哪个分区，再确定它的病在这一套实验里是什么角色。

第一步 保留原分区，清理重复照片

从 PlantSeg v7 的元数据取作业指定的 9 种植物，共 **4,349 张、43 个植物与病害组合**。像素完全重复审计排除 201 张；再对 436 对候选做目视核对，确认 213 对近重复，按重复组额外排除 209 张。清理后剩 **3,939 张**，这是 A/B 角色筛选前的总数。

第二步 给每种病定角色

对苹果、香蕉、玉米、大豆、番茄、小麦和西葫芦，分别把病名按**英文**字母排序。A 留第 1 个给验证、第 2 个给测试；B 留第 2 个给验证、第 3 个给测试。各自剩下的病是已知类。柑橘只作验证时的陌生植物对照，马铃薯只作测试时的陌生植物对照。

苹果病名的排序	A 的角色	B 的角色
1 黑腐病 (black rot)	验证用陌生病	已知病
2 花叶病毒病 (mosaic virus)	测试用陌生病	验证用陌生病
3 锈病 (rust)	已知病	测试用陌生病
4 疮痂病 (scab)	已知病	已知病

> **拿一张原来在训练区的苹果锈病照片举例**
> A 把锈病视为已知，可以拿这张照片训练。B 把锈病留作测试未知，因此训练区这张图不使用。B 只用原测试区里的锈病照片检查拒识。

训练区只用已知病。验证区用已知病和验证用陌生病；测试区用已知病和测试用陌生病。下表是冻结正式清单后的实际数量，两套各有 25 个已知类。

划分	训练 已知	验证 已知 / 陌生病 / 柑橘	测试 已知 / 陌生病 / 马铃薯
A	1,576	266 / 54 / 39	490 / 137 / 26
B	1,432	246 / 64 / 39	452 / 132 / 26

表中的「陌生病」指熟悉植物上的未知类别。A、B 是两套独立实验，同一张照片可能在两套中承担不同角色。

我们怎么训练和选模型

先用一次试跑核对代码和分数，再用统一设置比较两组。

两组都用 ResNet-18，训练目标不同

组别	训练时怎么学	验证和测试
基线组	看彩色照片，预测 25 个已知病类别，用真实病名计算分类误差。	只输入彩色照片。
病斑组	同时预测病名和像素级病斑位置。总损失为分类损失加 0.25 倍病斑损失。	只输入彩色照片，由分类分数决定病名或拒绝。

两组从同一套 ImageNet 通用预训练权重开始。照片保持长宽比，长边缩到 224 像素后填充成正方形；训练可做水平翻转和轻微颜色增强。病斑组的二值标注与照片同步变换，填充区不计入病斑损失。验证和测试使用固定预处理。

试跑 检查整个流程能否跑通

先用 A、种子 42 和一档学习率训练两个模型。重新加载权重，复核分类和开放集分数，并检查病斑标注只参与训练。试跑用的是近重复审计前的数据清单。

试跑验证指标	基线	病斑组
已知病准确率	78.78%	81.65%
熟悉宿主 AUOSCR，MaxLogit	0.6078	0.6274

正式实验 24 次训练，再冻结后测试

2 套划分 × 3 个种子 × 2 档学习率 × 2 组模型 = 24 次。 每次在 Mac GPU 上训练 20 轮，每批 32 张，使用 AdamW。种子是 42、123、2026；学习率候选是 0.0001 和 0.0003。每次保留已知验证 Macro-F1 最好的一轮。

验证比较了最大 Softmax 概率、最大 logit 和负能量三种分数。基线的验证表现选出两组共用的 MaxLogit，即模型输出中最大的分类原始分数。A 和 B 都选到 0.0001，最后每套用两组各三个种子测试，共 12 个模型。

> **程序怎么决定要不要说「不认识」**
> 用已知验证照片为每个模型定阈值，使约 95% 的已知验证照片能通过。正式测试时，分数达到阈值就输出得分最高的病名，低于阈值则输出 unknown。

正式测试跑出了什么

每套划分各 3 个种子。下表用冻结的 MaxLogit 规则。

指标（均值 ± 标准差）	A 基线	A 病斑	B 基线	B 病斑
已知病准确率	78.50% ± 1.23%	78.44% ± 0.42%	74.71% ± 0.92%	74.78% ± 0.80%
已知病 Macro-F1	0.7578 ± 0.0203	0.7589 ± 0.0095	0.7017 ± 0.0099	0.7031 ± 0.0065
陌生病 AUOSCR	0.6245 ± 0.0115	0.6316 ± 0.0048	0.6007 ± 0.0119	0.5987 ± 0.0141
陌生病 AUROC	0.7333 ± 0.0081	0.7425 ± 0.0032	0.7367 ± 0.0109	0.7345 ± 0.0122
陌生病误接收率	82.48% ± 4.44%	82.97% ± 5.28%	75.25% ± 5.16%	76.52% ± 4.22%
马铃薯对照 AUOSCR	0.6385 ± 0.0231	0.6441 ± 0.0248	0.6386 ± 0.0069	0.6426 ± 0.0074
测试已知病接收率	92.52% ± 0.96%	92.72% ± 0.72%	91.08% ± 0.34%	92.18% ± 0.78%
测试已知病认对且接收率	75.65% ± 1.39%	75.71% ± 0.41%	71.53% ± 0.51%	72.05% ± 1.05%

陌生病指标使用 A 的 137 张和 B 的 132 张熟悉宿主未知图。马铃薯对照在每套均为 26 张，需单独解读。

这些分数该怎么看

准确率看整体答对多少，Macro-F1先分别算每种已知病的 F1，再等权平均。AUROC看分数能不能把已知和陌生病排开。AUOSCR则同时要求模型能拒绝陌生病、也能答对被接收的已知病。**误接收率**只看冻结阈值下，有多少陌生病被硬猜成了已知病。

病斑组是否达到我们事先定的标准?

AUOSCR 的配对差值（病斑减基线）在 **A 平均 +0.0071**，3 个种子有 2 个提高；在 **B 平均 -0.0020**，3 个种子有 1 个提高。两套的已知病 Macro-F1 基本持平，满足容差；两套都未达到 +0.02 的 AUOSCR 门槛。

划分	种子 42	种子 123	种子 2026	配对差值均值 ± 标准差
A	+0.0049	+0.0200	-0.0036	+0.0071 ± 0.0120
B	-0.0019	+0.0044	-0.0084	-0.0020 ± 0.0064

实际效果 病斑组对已知病的准确率约 75% 到 78%。在固定阈值下，每遇到 10 张熟悉植物上的陌生病照片，大约 8 张仍会被当成已知病。

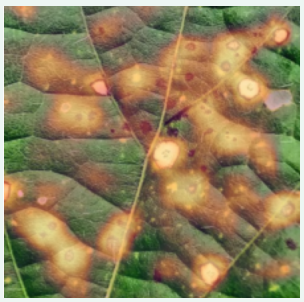
为什么会这样，接下来做什么

用冻结权重回到验证集看实际例子，区分看到症状和认出病名。

验证排查 病斑分支学到了什么

重新运行了 12 份冻结权重在验证图上的预测，接收计数与原验证表一致。部分高亮区域确实落在肉眼可见的症状上，例如大豆叶片上的圆斑；也有照片的背景被点亮。没学过的病同样可能出现很强的病斑响应。

已知 · 大豆蛙眼叶斑病



未知 · 玉米大斑病

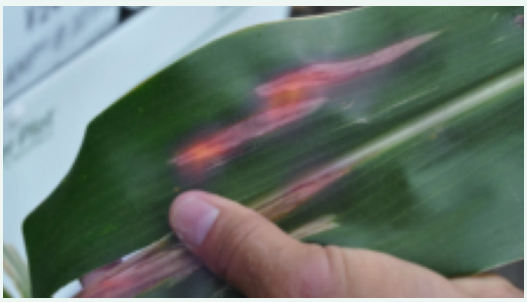


图 1 B 划分的两个验证例子。颜色越亮，三个种子的平均病斑预测分数越高。未用验证标注掩膜，这些图只能作定性检查。

验证排查 陌生病是怎么被猜错的

右图的玉米大斑病被两组三个种子都误接收。在 B 的全部玉米大斑病验证图中，病斑组三个种子共做 27 次判断，24 次误接收，其中 18 次猜成玉米灰斑病。两个病的叶片都可能出现长条状斑，外观相似是一个解释线索，热图本身无法证明分类依据。

验证集陌生病误接收	基线	病斑组
A	136/162（84.0%）	133/162（82.1%）
B	140/192（72.9%）	143/192（74.5%）

当前决定与剩余交付

保留本轮正式对照。结果支持「已知病分类基本持平」，但没有显示拒识能稳定改善。当前证据不足以将问题归因于 ResNet-18 或 AdamW。报告里可以用这些例子解释为什么找得到症状，仍可能认错病。

接下来补齐至少三种相关方法的比较、云端干净环境复现、英文正式报告（最多 5 页）和推理视频（最多 3 分钟）。最终报告还需写明 AI 使用和组员贡献。完成后再整理交接包。

材料来源 AIP304 CW2 Task Sheet §2、§4–6；PlantSeg v7；Predict.ipynb；Formal_Experiment.ipynb；冻结配置、正式测试 JSON 和验证排查记录。